Estudio sobre el Riesgo de Ataques Cardiacos

- Reducción de Dimensiones
- **Javier Martinez Reyes**

Diplomado Ciencias de Datos — Generación 33 • FES Acatlán, UNAM • Marzo 2026

Introducción & Motivación

El Problema

Un dataset de 1,319 pacientes con 8 variables fisiológicas. La alta dimensionalidad dificulta identificar patrones que distingan pacientes con mayor probabilidad de sufrir un ataque cardiaco.

La Solución

Tres técnicas de reducción de dimensiones — PCA, MDS Métrico y t-SNE — proyectan los datos a 2D preservando estructura y revelando clusters de riesgo.

El Objetivo

Proyectar los datos a 2D para identificar visualmente patrones que distingan pacientes de alto riesgo, comparando métodos lineales y no lineales.

Dataset & Variables Clínicas

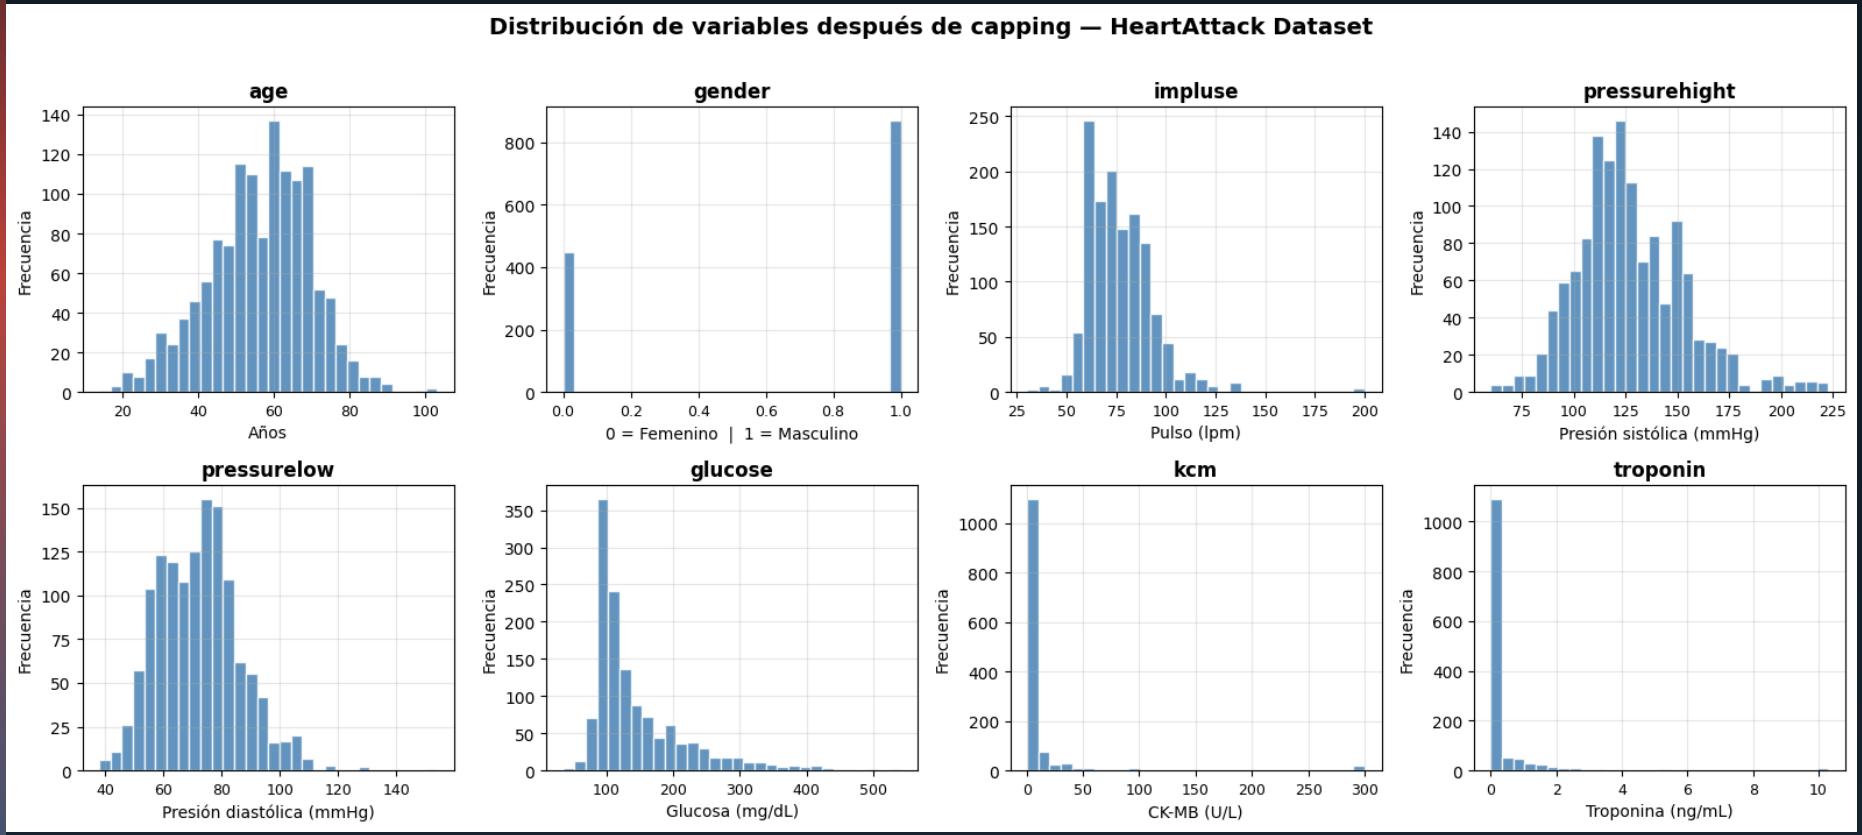

Limpieza de datos

- Capping con límites fisiológicos en age, impluse, pressurehight, pressurelow
- Biomarcadores kcm y troponin intactos — valores extremos son señal clínica
- Se excluye gender (binaria, distorsiona geometría euclidiana)
- Estas siete variables restantes son biomarcadores fisiológicos continuos directamente relacionados con el riesgo cardiaco, y son las que aportan más varianza explicable al análisis.

7 variables continuas seleccionadas para reducción de dimensiones

Dataset: HeartAttack.csv
n = 1,319 pacientes | 8 variables fisiológicas

Reducción con PCA y MDS

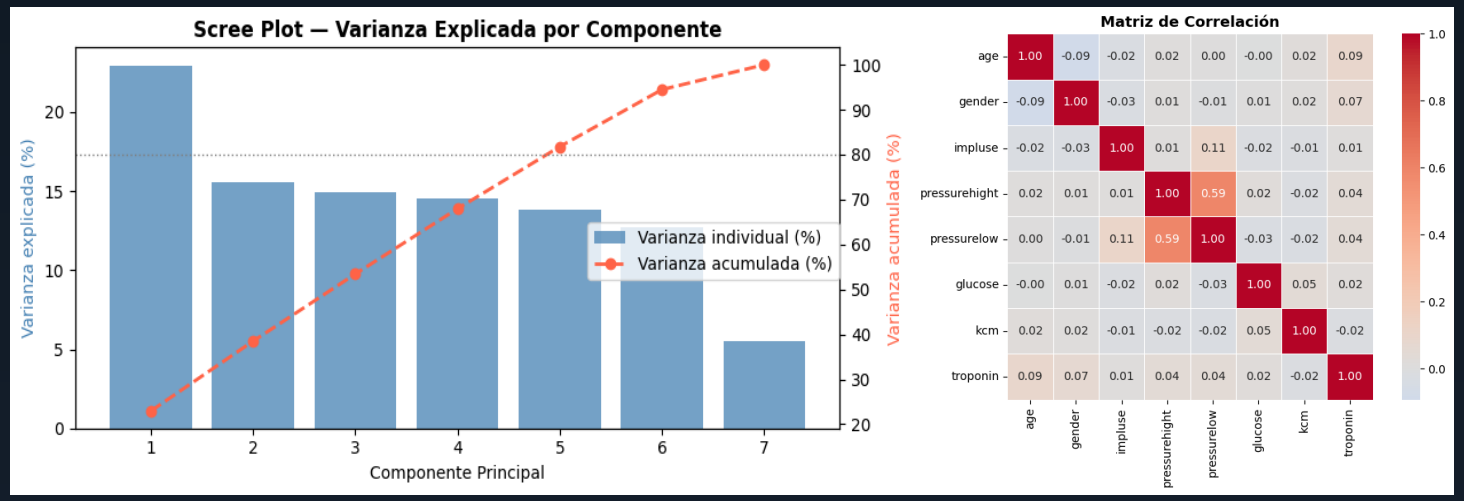

PCA

- PCA no es optimo para este análisis debido a que no hay linealidad entre las componentes. Las primeras dos componentes apenas si poseen un 38% de varianza explicada.

MDS

- MDS Métrico logra concentrar el 94% de la varianza proyectada en dos componentes, lo que indica una proyección bien distribuida en el plano. Sin embargo, el stress elevado sugiere que las distancias euclidianas originales en el espacio de 7 dimensiones no se preservan fielmente probablemente porque la estructura del dataset no es bien representable en 2D con distancias exactas. Esto es consistente con la baja correlación entre variables observada en la matriz de correlación.

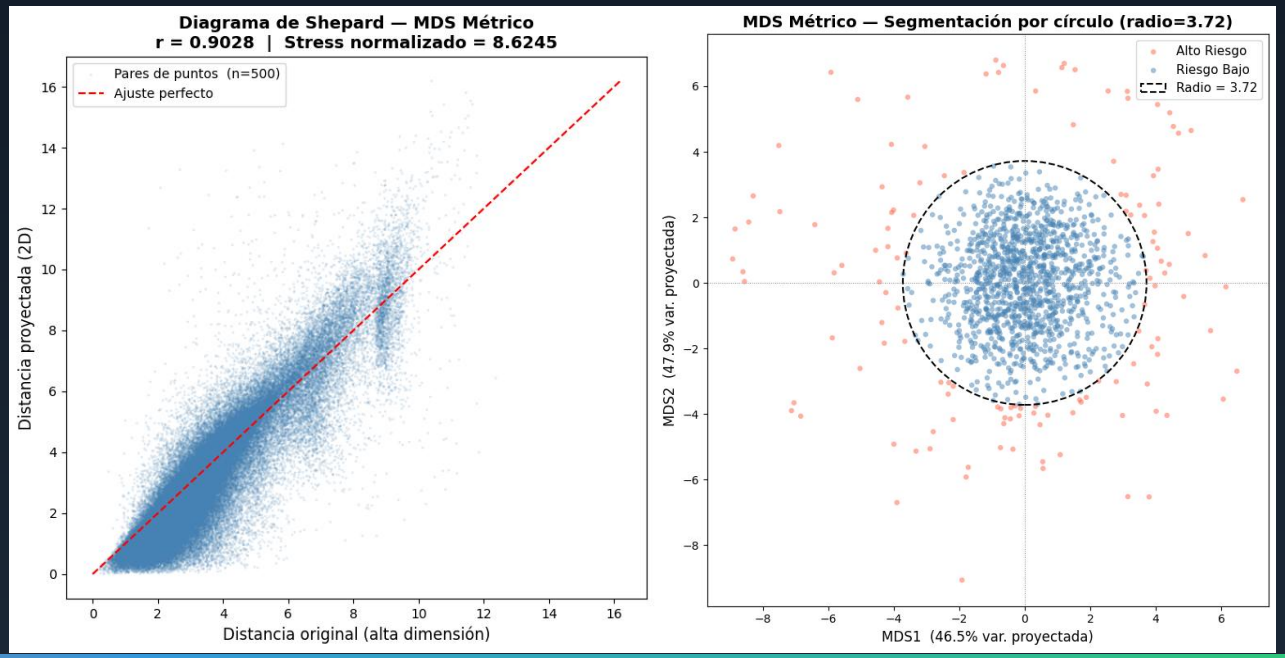

t-SNE: Visualización de grupos

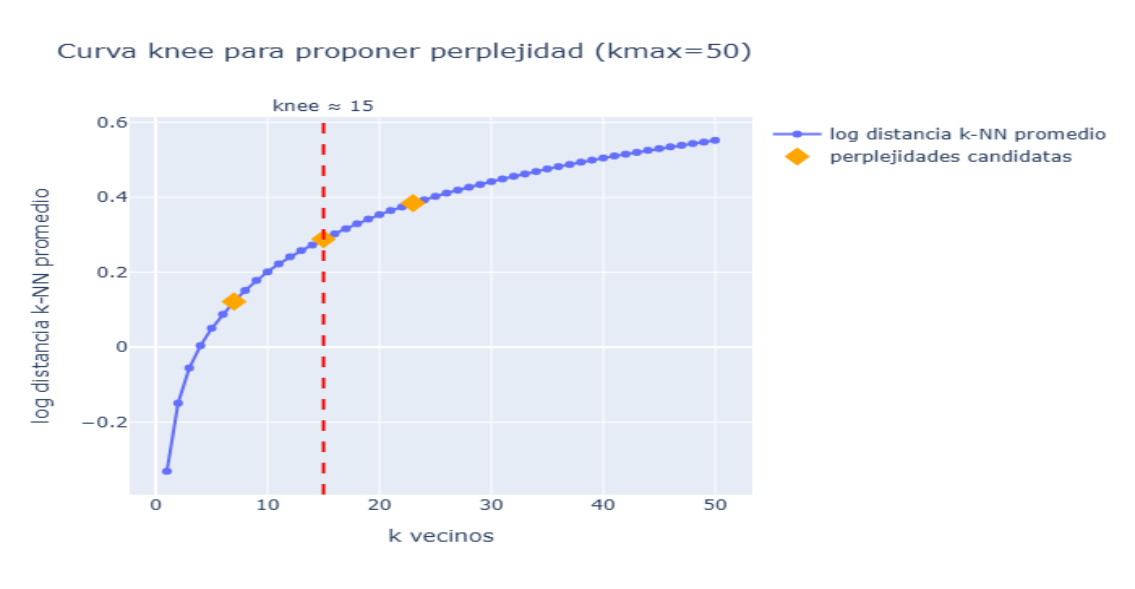

Análisis t-SNE

- La curva k-NN (gráfica izquierda) muestra el punto de inflexión en k ≈ 15 — el balance óptimo entre capturar estructura local sin introducir ruido.
- Polígono manual sobre proyección 2D
- Interior = Riesgo Bajo/Moderado
- Exterior = Alto Riesgo

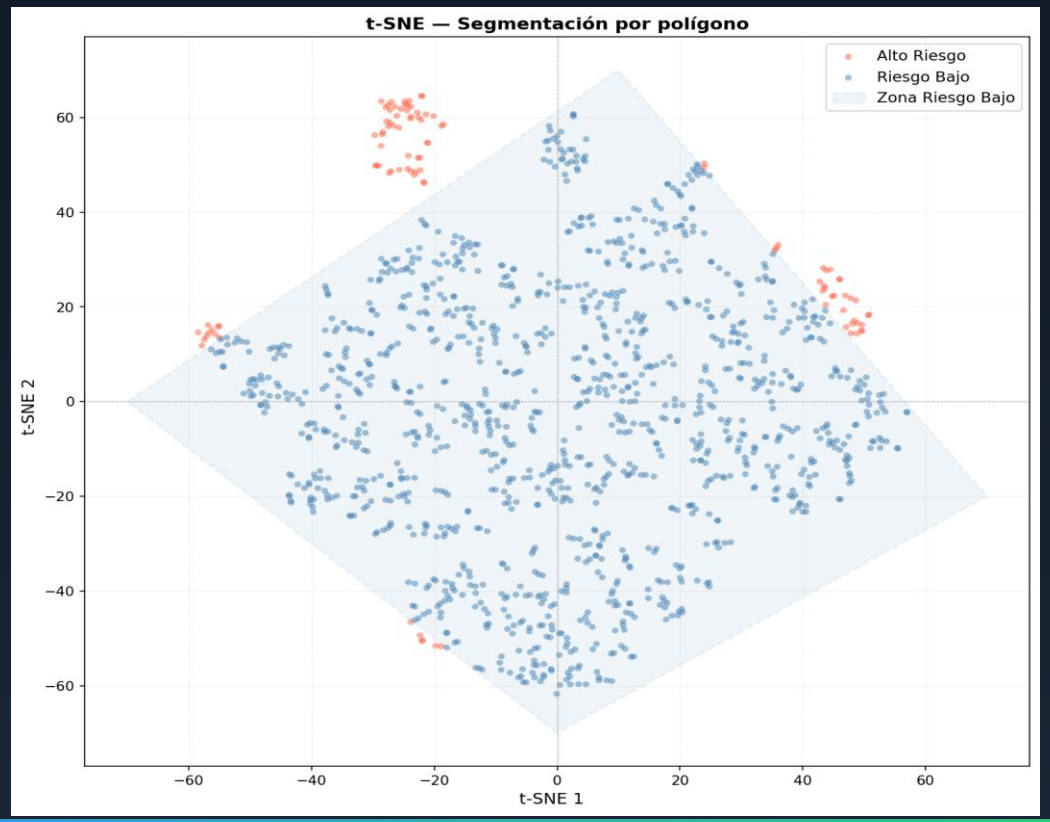

Segmentacion

- t-SNE tiende a formar grupos compactos separados cuando hay estructura local coherente. El interior del polígono está dominado por puntos azules, lo que valida que la región central de t-SNE agrupa pacientes con biomarcadores dentro de rangos normales.
- La dispersión de los rojos en múltiples zonas periféricas sugiere que no hay un único patrón de riesgo cardiaco — algunos pacientes tienen troponina alta, otros CK-MB alta, otros combinaciones distintas. t-SNE los separa del núcleo pero no los agrupa entre sí porque sus perfiles locales son distintos.

Conclusiones & Hallazgos

Conclusiones Principales
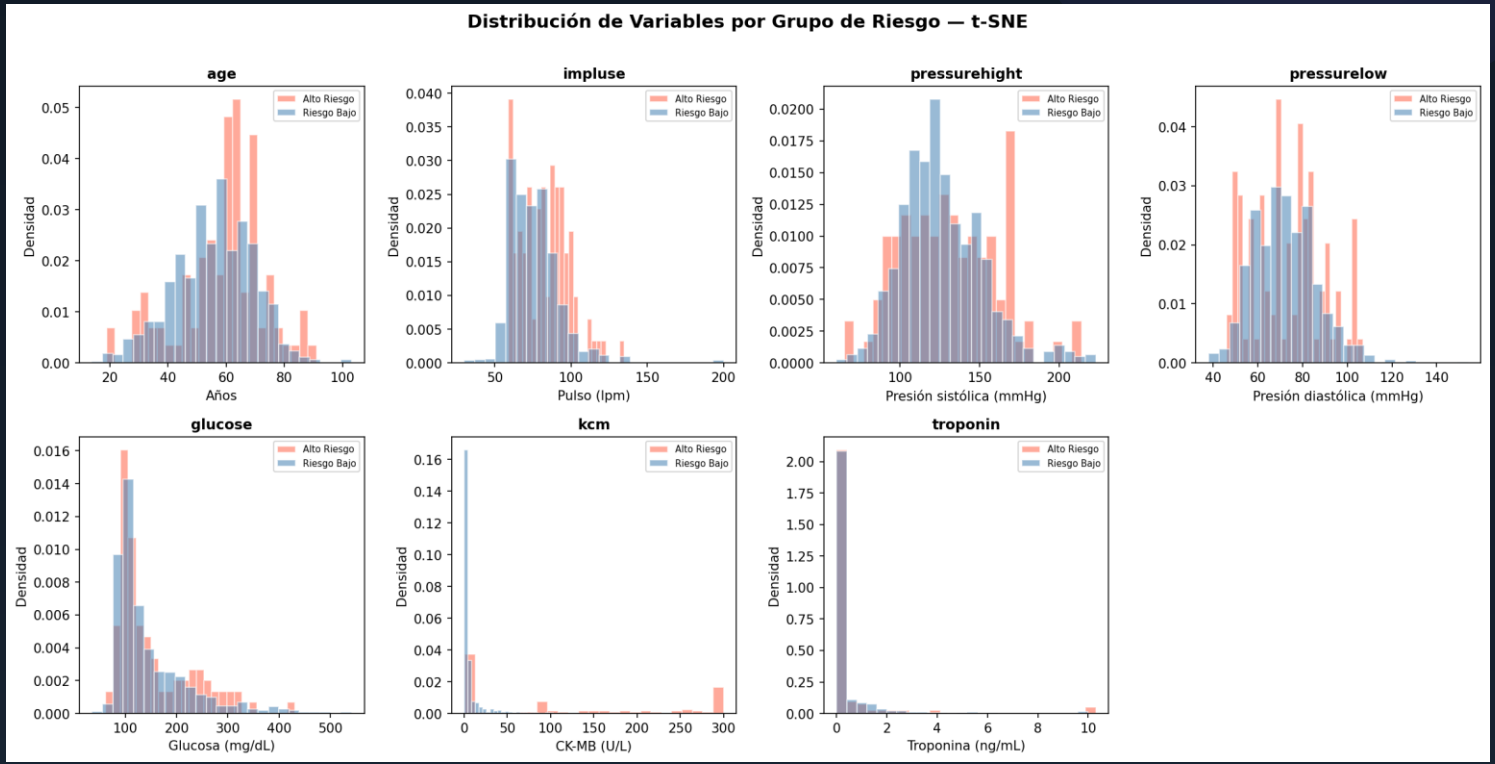
1. t-SNE es el método más adecuado: revela clusters no lineales invisibles a PCA y MDS
2. La edad de los pacientes de alto riesgo compre entre 45 -70 aaños.
3. El pulso tiene a ser más alto entre pacientes de alto riesgo.
4. Aunque no hay una clara separación entre los niveles de glucosa sí se puede observar que hay más pacientes de alto riesgo con una alta glucosa que pacientes sanos con alta glucosa.
5. El KMC sí se muestra elevado en pacientes de alto riesgo.
6. Los pacientes de alto riesgo pueden filtrarse de mejor forma creando más grupos con tsne.